

Université de Franche-Comté

Construction d'un DST : autres propositions

par Christophe Enderlin

le~2 octobre 2014

Chapitre 1

Contexte

1.1 Rappel

Pour mémoire, voici une représentation graphique du déroulement des opérations lors de l'insertion d'un nouveau nœud dans le DST, sans équilibrage de charge, pour simplifier. (voir page suivante)



1.2 Situation

À l'issue de nombreux tests, la première version de mon simulateur a montré son manque de robustesse : lorsqu'un grand nombre de nouveaux arrivants impactent la même zone du DST à un même moment, les choses se passent mal. L'ensemble des problèmes observés semble pouvoir être ramené aux deux points suivants :

1.2.1 Le foisonnement des requêtes/réponses se passe mal

Voici un exemple de cas de figure qui pose problème :

2 nœuds intègrent le DST via un même contact :

- Node $14 \rightarrow Node \ 121 \rightarrow Node \ 42$ (intégration rapide, pas de scission requise)
- Node 249 \rightarrow Node 121 \rightarrow Node 42 (scissions et ajout d'étage requis)
- Alors que Node 121 est en attente de ACK_CNX_REQ/249 de 42, il reçoit
 ACK_CNX_REQ/14 de 42. Il le stocke donc puisque ce n'est pas la réponse qu'il attend.
- Node 14 ne recevant pas la réponse de 121 reste en 'b'. À ce stade de l'intégration, il fait déjà partie du DST et il reçoit donc ADD_STAGE/249 mais il ne peut y répondre ⇒ deadlock.

Comme on le voit, le fait que ACK_CNX_REQ/14 soit stocké par 121 pose problème ici.

Un seul process (hébergé par *Node* 121) chargé de l'intégration de deux nouveaux nœuds différents attend deux réponses. Le problème vient alors du fait qu'il ne peut pas traiter les réponses du premier pendant qu'il est occupé avec le deuxième. Ce mécanisme n'est donc pas correct.

On pense alors à deux solutions possibles : a) utiliser la fonction MSG_comm_waitany() de Simgrid (elle permet de réagir à une réponse parmi celles attendues) b) utiliser plusieurs process dédiés, chacun gérant ses propres requêtes/réponses .

La deuxième solution semble permettre de bien séparer les tâches, ce qui aurait un double avantage : arrêter de mélanger les requêtes/réponses pour différents nouveaux arrivants, et présenter une trace d'exécution plus lisible.

1.2.2 L'échec d'une diffusion d'un SET_UPDATE est mal géré

Pour rappel, lorsque l'arrivée d'un nouveau nœud requiert des scissions, on diffuse un SET_UPDATE sur l'ensemble du sous-arbre impacté dans le but de placer un verrou (l'état 'u') sur l'ensemble de ses nœuds. Ainsi, les seules requêtes qu'ils accepteront seront celles qui concernent cet ajout (les autres sont soit refusées, soit différées).

 $^{1.\}$ Autrement dit, un accusé réception d'une requête de demande de connexion pour le nouveau nœud 249

Lorsque cette diffusion échoue (parce qu'on tombe sur une partie déjà verrouillée pour un autre arrivant, par exemple), on se retrouve dans la situation où une partie du sous-arbre a été verrouillée pour le nouveau nœud courant, et une autre pour un autre nouveau nœud. Il est donc important de remettre les choses en état (ôter les verrous posés par la diffusion en échec) pour ne pas bloquer les choses.

Les tests ont montré que la méthode utilisée pour cela n'est pas correcte puisqu'on arrive malgré tout à générer des *deadlocks*, les deux sous-arbres se bloquant mutuellement.

Il faut donc trouver des solutions pour ces deux problèmes.

Chapitre 2

Proposition de solutions

2.1 Solution au premier point

Principes de base:

- Chaque demande d'insertion de nouveau nœud est traitée par un process distinct créé pour l'occasion
- Ce sous-process ne peut pas recevoir de réponses à des requêtes qu'il n'a pas émises.
 Dit autrement, il doit (et peut) traiter immédiatement toutes les réponses reçues.
 (plus besoin de différer ou de refuser)
- Plusieurs nouveaux nœuds utilisant le même contact ne pouvant pas être traités simultanément, un mécanisme de file d'attente pour les traiter séquentiellement est mis en place.

De plus, j'ai fait le choix d'utiliser aussi un tel sous-processus pour les diffusions de SPLIT et de CS_REQ parce que là encore, cela semble être un avantage de ne pas mélanger les réponses attendues dans le cas de diffusions croisées.

Le schéma général de cette solution à process multiples est présenté figure 2.1 en page 8.

Remarque préliminaire: launch_fork_process() est une fonction chargée de choisir comment exécuter les requêtes qui lui sont transmises. Elle les confie soit à un nouveau process (cas de CNX_REQ, BR_SPLIT, BR_CS_REQ), soit au process courant.

Explications: On utilise au plus trois process par nœud.

- 1. Main_Proc Comme son nom l'indique, c'est le process principal :
 - il se charge des initialisations et de la création du process Tasks_Queue (qui tourne tout le temps de la simulation).
 - il héberge les files *tasks_queue* (les tâches CNX_REQ reçues en attente de traitement) et *delayed tasks* (les tâches différées)

Process calls sequence

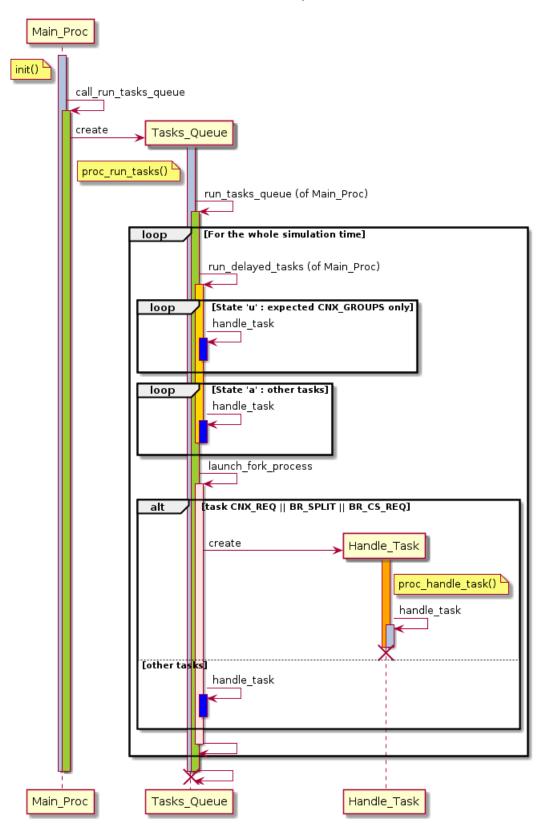


Figure 2.1 – Séquence d'appels des sous-process

- lorsqu'il reçoit une requête, a) soit il la place dans la file tasks_queue (cas des CNX_REQ), b) soit il la transmet à launch_fork_process(), c) soit il la place dans la file delayed_tasks.
- il héberge ses propres files *async_answers* et *sync_answers* (les réponses asynchrones et synchrones attendues aux requêtes qu'il a émises)

2. Tasks_Queue

Ce process est chargé d'exécuter la fonction run_tasks_queue() qui traite les files tasks_queue et delayed_tasks. Il héberge aussi ses propres files async_answers et sync_answers.

3. Handle_Task

C'est ce process qui est éventuellement créé par launch_fork_process() depuis run_tasks_queue() pour traiter les requêtes concernées. Il héberge aussi ses propres files async_answers et sync_answers.

2.1.1 Dans le détail

run tasks queue() (voir figure 2.2 en page 11)

La file *tasks_queue* contient toutes les demandes de connection (c'est à dire toutes les tâches CNX_REQ) reçues par le nœud qui héberge cette file. run_tasks_queue() est donc chargée de traiter les requêtes présentes dans cette file, par ordre de priorité. ¹

Après avoir traité les tâches différées (voir détails run_delayed_tasks() plus loin), on s'occupe de la file tasks queue proprement dite, à condition d'être actif (à l'état 'a').

Le nœud courant possède deux variables "de nœud" (c'est à dire globales à tous les process hébergés par ce nœud) :

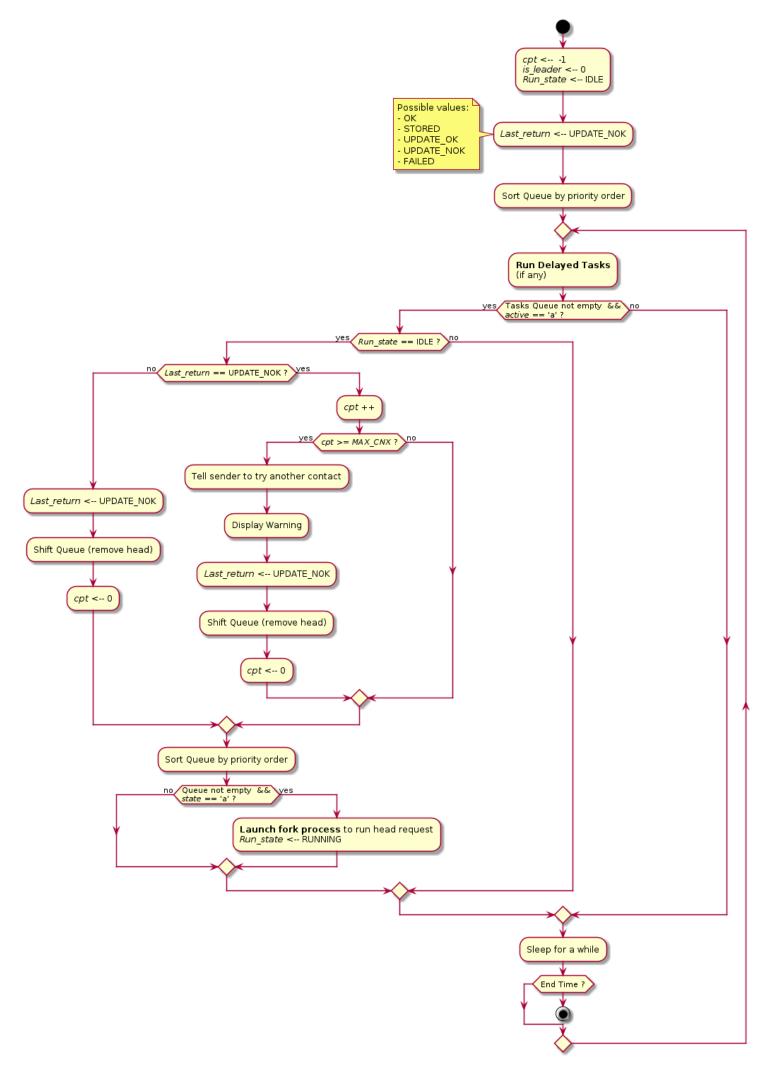
- Run_state : Chaque requête de cette file sera traitée par un process distinct, mais il n'est pas possible ici d'insérer plus d'un nouveau nœud à la fois et il faut donc que ces process s'exécutent séquentiellement. C'est la raison d'être de cette variable Run_state : pour s'occuper de la tâche suivante, la tâche courante doit être terminée. (valeur IDLE)
- Last_return : Cette variable contient la valeur de retour de l'exécution courante de connection_request().

Il y a deux sortes d'échec d'insertion possibles. Lors de l'arrivée d'un nouveau nœud, on a la séquence d'appels suivante : nouveau $nœud \rightarrow contact \rightarrow leader$. En cas d'échec, le contact doit refaire une tentative plus tard, mais son leader peut avoir changé entre temps. Le leader doit donc dépiler la requête alors que le contact doit la conserver dans sa file $tasks_queue$. Deux valeurs de retour en cas d'échec sont alors requises : un leader retourne la valeur FAILED alors qu'un contact retournera la valeur UPDATE NOK.

Comme on peut le voir, dans le cas général (i.e. $cpt < MAX_CNX$), une valeur de retour $UPDATE_NOK$ laisse la requête dans la file pour une nouvelle tentative un peu

^{1.} voir plus loin les remarques à ce sujet

plus tard ("Sleep for a while"). Dans le cas contraire, on dépile pour passer à la requête suivante. (On voit donc qu'en cas de retour FAILED, la requête est bien dépilée.)



 $FIGURE 2.2 - run_tasks_queue()$

En détails : À l'issue de l'exécution de connection_request(), une réponse est envoyée à l'émetteur seulement dans les cas où la requête est ici dépilée.

Lors d'un échec, voici alors ce qu'il se passe dans la séquence de retour $leader \rightarrow contact \rightarrow nouveau \ nœud$: le leader reçoit FAILED comme valeur de retour de connection_request(), il dépile donc sa requête et répond $UPDATE_NOK$ à son contact. Celui-ci ne dépile rien et ne répond pas à $nouveau\ nœud$. La requête restant dans la file s'exécutera alors au plus $MAX\ CNX$ fois.

Si ce nombre est atteint, on décide alors de dépiler tout de même la requête et de répondre *UPDATE_NOK* au nouveau nœud. Il peut ainsi détecter l'échec et refaire d'autres tentatives avec d'autres contacts. (ces contacts sont alors choisis aléatoirement parmi les nœuds déjà intégrés au DST. Il s'agit d'un tableau global, donc introduisant un peu de centralisation dans cet algorithme. ²)

Que la file soit dépilée ou pas, elle est à nouveau triée par ordre de priorité à ce momentlà. En effet, pendant le temps d'exécution de connection_request(), d'autres demandes d'insertion ont pu arriver dans la file et il faut s'assurer que la prochaine à exécuter soit bien la suivante en termes de priorité.

L'exécution d'une requête de la file est confiée à launch_fork_process() (voir plus haut)

```
run delayed tasks() (voir figures 2.3 et 2.4 en pages 13 et 15)
```

Cette fonction est chargée de traiter la file des tâches différées (delayed_tasks). Lorsqu'une tâche ne peut pas être exécutée par un nœud, soit elle est refusée (et retournée à l'émetteur), soit elle est stockée dans cette file pour être exécutée plus tard. Cette fonction est donc appelée périodiquement. (Voir run_tasks_queue())

On distingue deux cas : soit le nœud courant est à l'état 'u', soit il est à 'a'.

état 'u' (voir partie 1 - figure 2.3 en page 13)

Variables:

- nb elems: contient le nombre d'éléments de la file au lancement de run_delayed_tasks()
- -cpt: itérateur (de 0 à nb elems)

Un nouveau nœud est alors en cours d'insertion et il faut examiner ce cas en premier pour minimiser les risques de blocages. Les seules tâches exécutables ici sont celles qui pourraient permettre de terminer cette insertion, c'est à dire les CNX_GROUPS pour le même nouveau nœud que celui en cours d'insertion. (c'est le test task.args.new_node_id == state.new_node_id)

On parcourt donc la file à la recherche de ces tâches pour les exécuter. (handle_task(task))

^{2.} Voir commentaires en conclusion

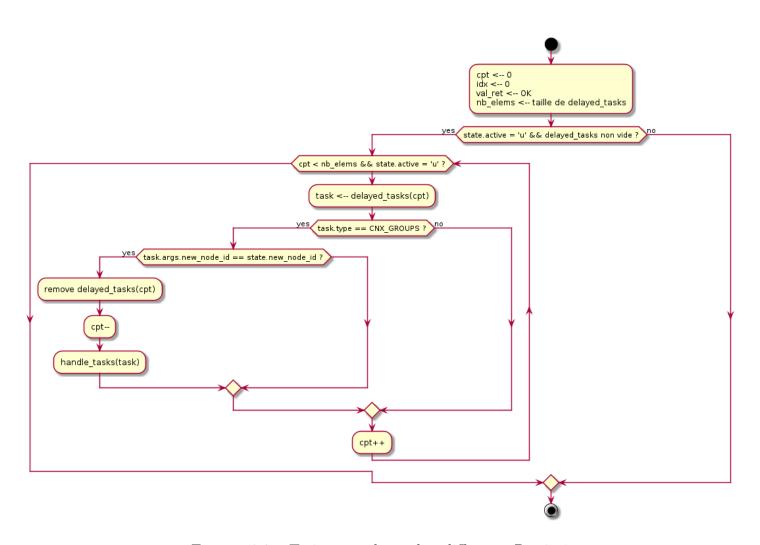


FIGURE 2.3 – Traitement des tâches différées - Partie 1

Lorsqu'on en trouve une, on peut l'ôter de la file sans s'assurer que son exécution a réussi ou pas puisque si elle échoue, elle est à nouveau stockée dans la file.

À noter: à l'issue de la fonction handle_tasks(), le nombre de tâches de la file a pu augmenter. Pourtant, on choisi de ne pas mettre à jour la variable nb_elems ici pour ne pas risquer une boucle sans fin. Si des tâches ont été ajoutées entre temps, elles seront traitées lors d'une prochaine exécution de run_delayed_tasks().

état 'a' (voir partie 2 - figure 2.4 en page 15)

Ici, le nœud courant est prêt à exécuter n'importe quelle autre tâche et on peut traiter le reste de la file.

Variables:

- nb elems : le nombre d'éléments restants de la file.
- -idx: itérateur (de 0 à nb_elems)
- is_contact : vaut 1 si le nœud courant est le contact direct du nouveau nœud. (autrement dit, si l'émetteur de la tâche à exécuter est le nouveau nœud)
- buf_new_node_id: task.args.new_node_id est mémorisé dans cette variable parce qu'on en a besoin après la destruction de task.

On ôte la tâche courante de la file dans les cas suivants :

- l'exécution a réussi (OK et UPDATE OK)
- la tâche a été stockée à nouveau (STORED)
- l'exécution a échoué mais le nœud courant n'est pas le contact direct du nouveau nœud. (UPDATE_NOK &&!is_contact) Il s'agit du cas FAILED décrit plus haut.

À noter : si le nœud courant était verrouillé pour le même nouveau nœud que celui dont la tâche vient d'échouer, alors on ôte le verrou.

A l'issue de l'exécution de cette boucle (idx == nb_elems), la file n'est pas forcément vide. Elle contient toutes les tâches dont l'exécution a échoué et celles qui ont été stockées – y compris par d'autres process – entre temps. Cette boucle est alors à nouveau exécutée jusqu'à ce que nb_elems soit à 0, c'est dire jusqu'au succès de toutes les tâches qui se trouvaient dans cette file au moment de cet appel de run_delayed_tasks(). Comme indiqué précédemment, les tâches ajoutées entre temps ne seront pas traitées lors de cette exécution.

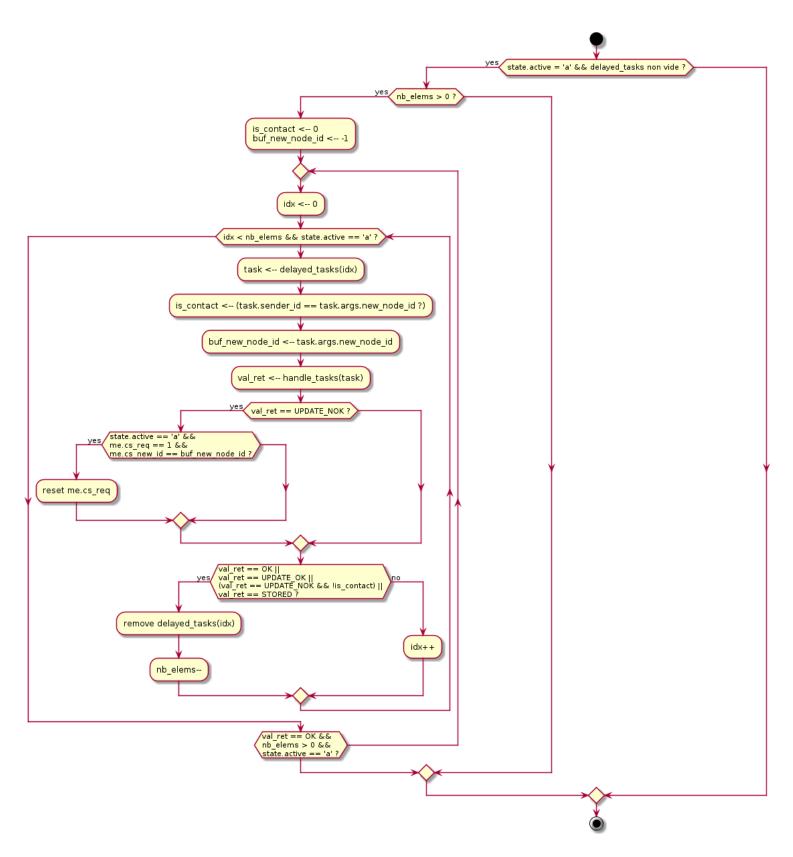


FIGURE 2.4 – Traitement des tâches différées - Partie 2

Launch fork process

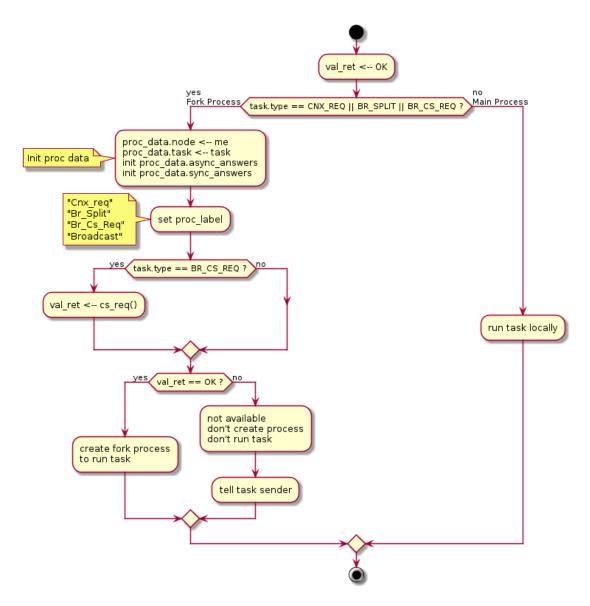


FIGURE 2.5 – Launch Fork Process

Si la tâche transmise à cette fonction n'est ni une demande de connexion (CNX_REQ), ni une diffusion de SPLIT ou de CS_REQ, alors elle est exécutée localement, c'est à dire par le process courant. Sinon, elle est confiée à un nouveau process créé pour l'occasion.

Ce nouveau process doit posséder ses propres files d'attente de réponses attendues (async_answers et sync_answers) de sorte qu'elles ne puissent plus être mélangées avec celles requises pour l'insertion d'un autre nouveau nœud.

Il est labelisé ainsi : xxx-nom_process-yyy où :

- xxx est l'id du nœud courant
- nom_process est le nom attribué par cette fonction (tel que "Cnx_req" ou "Br_split", etc)
- yyy est l'id du nouveau nœud en cours d'insertion

On s'assure ainsi de l'unicité de l'étiquette de ce process.

Dans le cas où la tâche est une diffusion de CS_REQ (demande d'entrée en section critique), on commence par s'assurer que le nœud courant est disponible (c'est à dire répondrait favorablement à un CS_REQ) pour ne pas créer de process fils inutilement. En cas de non-disponibilité, il faut en informer l'émetteur de la requête.

2.2 Solution au deuxième point

Parler du mécanisme de CS_REQ.

Chapitre 3

Les fonctions de communication

3.1 Comparaison des requêtes synchrones et asynchrones

3.1.1 Synchrone

La requête synchrone est utilisée lorsqu'une réponse est attendue pour poursuivre l'exécution du programme.

Cas d'emplois principaux : 1

- CNX_REQ (fonction join()) La réponse attendue est la table de routage du contact qui a réussi l'insertion du nouveau nœud
- BROADCAST (fonction handle_task():BROADCAST) La réponse attendue ici est la valeur de retour de la fonction handle_task(), c'est à dire le succès ou l'échec de la requête diffusée.

De plus, on utilise aussi ce type de requête pour retransmettre au leader les requêtes ${\tt CNX_REQ}$ et ${\tt SPLIT_REQ}.^2$

L'attente de la réponse ne devant pas être bloquante, toutes les requêtes ou autres réponses arrivant dans l'intervalle doivent être traitées.

Déroulement simplifié des opérations L'émetteur de la requête appelle send_msg_sync() qui exécute les tâches suivantes :

- crée la requête
- encapsule la requête dans une tâche
- empile la requête sur $sync_answers$
- envoie la tâche au destinataire
- attend la réponse

^{1.} Pour simplifier, la phase d'équilibrage de charge est ignorée ici.

^{2.} Pas forcément utile dans le cas de ${\tt SPLIT_REQ},$ à voir

- traite tout ce qui est reçu qui n'est pas la réponse
- dès que la réponse est reçue, dépile la requête de sync answers
- retourne la réponse à l'appelant

3.1.2 Asynchrone

Dans ce type de requête, le destinataire renvoie un simple accusé réception à l'émetteur une fois la requête demandée effectuée. Ces accusés réception seront pris en compte ou pas selon les besoins de synchronisation.

Dans les deux cas, les opération se déroulent de cette façon : L'émetteur appelle send_msg_async() qui exécute les tâches suivantes :

- crée la requête
- encapsule la requête dans une tâche
- envoie la tâche au destinataire

Puis deux cas se présentent :

Un accusé réception est attendu Cas des requêtes suivantes :

- BROADCAST (fonction broadcast())
- NEW_BROTHER_RCV (fonction connection_request())
- DEL_PRED (fonctions connect_splitted_groups(), split())
- ADD_PRED (fonction connect_splitted_groups())
- CNX_GROUPS (fonction split())

L'émetteur empile alors la requête sur $async_answers$ puis, lorsque plusieurs requêtes ont été émises, il appelle wait_for_completion() pour arrêter le déroulement du programme jusqu'à ce que l'ensemble des accusés réception ait été reçu. ³ C'est cette fonction qui dépile les requêtes de $async_answers$ au fur et à mesure de leur réception et comme send_msg_sync(), elle traite aussi tout ce qu'elle reçoit entre temps.

Pas d'accusé réception Dans ce cas, l'appelant ne fait qu'exécuter send_msg_async().

3.2 send_msg_sync() - envoi synchrone

La fonction send_msg_sync() est chargée d'envoyer une requête à un autre nœud, puis d'en attendre la réponse.

Chaque process hébergé par un nœud possède deux files : sync answers et async answers.

^{3.} voir détails de wait_for_completion() plus loin

Ces deux files servent à stocker les requêtes synchrones et asynchrones (respectivement) émises, le temps qu'elles reçoivent une réponse et qu'elle soit lue. Ces requêtes sont dépilées dès que leur réponse a été prise en compte. ⁴

Lorsqu'une réponse est reçue, il y a trois cas possibles :

- 1. il s'agit de la réponse qu'on est en train d'attendre : Dans ce cas, la réponse est prise en compte, la requête correspondante est simplement dépilée et le traitement se poursuit.
- 2. il s'agit d'une autre réponse attendue : Elle est alors enregistrée dans la bonne pile, avec la requête correspondante
- 3. il ne s'agit d'aucune réponse attendue : Elle est simplement ignorée (cas de certains accusés réception, par exemple)

3.2.1 Déroulement de l'algo

Voir figures send_msg_sync() - pages 22, 23 et 24.

Première partie envoi de la requête

Après avoir construit la tâche contenant la requête, celle-ci est envoyée au moyen de la fonction isend() de Simgrid, puis stockée dans la pile $sync_answers$ du process courant. On attend ensuite la fin de la communication.

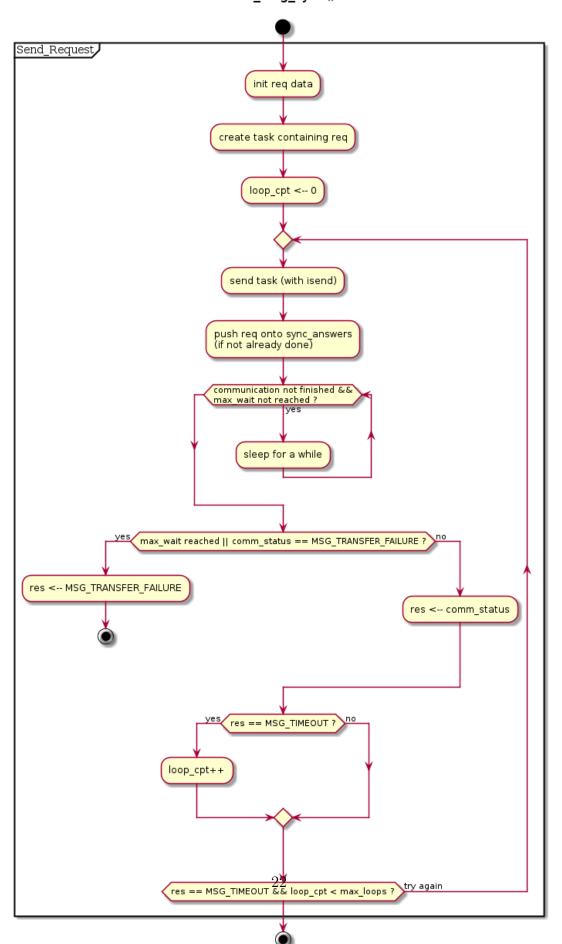
Deux traitements différents des cas d'échecs :

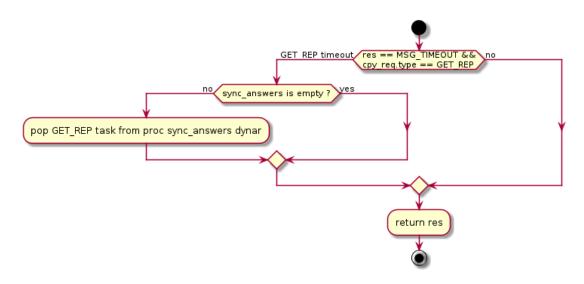
- la communication ne se termine pas (cas du process destinataire arrêté) ou elle a le statut MSG_TRANSFER_FAILURE (cas de l'hôte destinataire arrêté) : La fonction s'arrête en retourant une erreur de transmission.
- la communication se termine avec le statut TIMEOUT (cas d'un destinataire trop occupé, par exemple) : On recommence l'émission un certain nombre de fois (loop_cpt).
 Si max_loops est atteint, la fonction est également arrêtée avec une erreur de transmission.

Deuxième partie réception de la réponse

^{4.} Pour mémoire, la réponse à une requête synchrone contient les données demandées alors que la réponse à une requête asynchrone est simplement un accusé réception.

send_msg_sync()





 $\label{eq:figure 3.2-Algo send_msg_sync - Partie 3} Figure \ 3.2-Algo \ \text{send_msg_sync - Partie 3}$

Dans cette partie, le process courant se met en écoute de la réponse. En cas d'erreur de communication (res!= MSG_OK), on la signale et on se remet en écoute, sauf s'il s'agit d'un TIMEOUT pour une requête GET_REP. Dans ce cas, on arrête la fonction là en retournant simplement l'erreur pour la signaler à l'appelant.

GET_REP est traitée de cette façon pour supprimer une possibilité de deadlock. GET_REP demande à un nœud de fournir un autre représentant moins chargé pour un étage donné. S'il met trop de temps à répondre et qu'on abandonne, ça n'a pas d'autre conséquence que de conserver le même représentant. L'équilibrage de charge n'est alors pas optimum, mais on accepte le défaut pour l'instant.

Deux types de tâches peuvent être reçus : soit une requête, soit une réponse.

* Cas d'une requête : Si c'est une demande de connexion (CNX_REQ), elle est simplement stockée dans $tasks_queue$ (rappel : cette file est hébergée par le nœud courant). Sinon, on l'exécute avec handle_task().

Ensuite, on regarde dans la pile $sync_answers$ pour voir si la réponse attendue n'a pas été reçue entre temps. Si oui, elle est dépilée et on quitte la boucle de réception. Sinon, on se remet en écoute.

* Cas d'une réponse : On commence par regarder s'il s'agit de la réponse synchrone attendue. Si oui, elle est dépilée et on quitte la boucle de réception. Sinon, il peut s'agir d'une autre réponse attendue (synchrone ou asynchrone). Autrement dit, la requête correspondante à cette réponse est trouvée dans une des deux piles $sync_answers$ ou $async_answers$. Dans ce cas, la réponse est enregistrée avec sa requête dans sa pile et on se remet en écoute. S'il ne s'agit d'aucune réponse attendue, on peut l'ignorer simplement et se remettre en écoute.

Remarques: ********

- 1) Dans cette fonction, la requête en attente de réponse se trouve toujours au sommet de la pile : un process donné ne peut exécuter qu'une seule instance de send_msg_sync() à la fois, send_msg_sync() est la seule fonction susceptible d'empiler une requête dans sync_answers, et une pile sync_answers n'est associée qu'à un seul process. De ce fait, lorsqu'on reçoit une réponse à une requête synchrone attendue, il est facile de déterminer s'il s'agit de la réponse attendue ou d'une autre : la requête est au sommet de la pile ou pas.
- 2) Si send_msg_sync() n'est pas appelée par le process principal, elle ne peut pas recevoir d'autre message que celui qui est attendu.

send_msg_async() en détails *******************

Cette fonction réalise la même chose que la première partie de send_msg_sync(), à la différence qu'on n'empile pas la requête puisqu'on laisse le soin à l'émetteur de décider s'il faut le faire ou pas.

Une autre différence est qu'on ignore un éventuel défaut d'émission (res != MSG_OK) alors

que le programme est arrêté dans send_msg_sync(). Ce n'est pas volontaire, je n'ai juste pas encore étudié la tolérance aux pannes.

On attend ans_cpt réponses. Si max_wait est atteint avant que toutes les réponses aient été reçues et traitées, on quitte sur erreur, ce cas ne devant pas se produire.

wait_for_completion() pouvant s'appeler elle-même, il faut commencer par vérifier si des réponses attendues ont déjà été traitées par ces appels récursifs, et si oui, s'il en reste encore à traiter. C'est l'appel à check_async_nok() du début.

Si oui, on se met en écoute, et comme dans send_msg_sync(), il faut traiter tout ce qui est reçu dans l'intervalle.

- Requête : ******

Si c'est CNX_REQ, on l'empile sur *tasks_queue*, sinon, on l'exécute avec launch_fork_process(). On regarde ensuite si des réponses ont été reçues entre temps avec check_async_nok(), puis on se remet éventuellement en écoute.

- Réponse : ******
- Réponse asynchrone correspondant à une requête empilée : si elle fait partie de celles qui sont attendues, la requête correspondante est dépilée d'async_answers, après avoir mémorisé un éventuel échec de BROADCAST ou SET_UPDATE dans ret (pour du log) On se remet ensuite en écoute s'il reste des réponses à recevoir. (ans_cpt > 0)
- sinon, elle est enregistrée dans async answers
- Réponse synchrone attendue : si oui, elle est enregistrée dans $sync_answers$ sinon, elle est ignorée.